Методичні вказівки
до виконання лабораторної роботи №2
на тему «Вивчення модифікації алгоритму PageRank під парадигму MapReduce»

з курсу

“Обробка надвеликих масивів даних”

Київ – 2023

Мета роботи

Ознайомитися з алгоритмом PageRank та його модифікацією під парадигму MapReduce, навчитися використовувати PySpark для реалізації

модифікованого алгоритму PageRank та провести експерименти з великими даними.

План роботи

1. Ознайомлення з алгоритмом PageRank та його модифікацією під парадигму MapReduce. Дослідження основних понять та принципів роботи алгоритму PageRank, а також його модифікації під парадигму MapReduce.
2. Розробка модифікованого алгоритму PageRank за допомогою PySpark та алгоритму MapReduce. Реалізація модифікованого алгоритму PageRank за допомогою PySpark та алгоритму MapReduce, використовуючи підходи, що відповідають парадигмі MapReduce.
3. Проведення експериментів з великими даними (на скільки це можливо). Використання розробленого модифікованого алгоритму PageRank для обробки великих даних та проведення експериментів з різними параметрами алгоритму.
4. Аналіз результатів та порівняння зі стандартним алгоритмом PageRank. Аналіз результатів експериментів та порівняння їх з результатами, отриманими за допомогою стандартного алгоритму PageRank
5. Підготувати протокол з результатами виконання роботи, який має містити наступні пункти:
    1. Кроки налаштування середовища
    2. Запуск та пояснення роботи програми «PageRank» на щонайменше 5-ти різних наборах даних
    3. Відповідь на теоретичні запитання

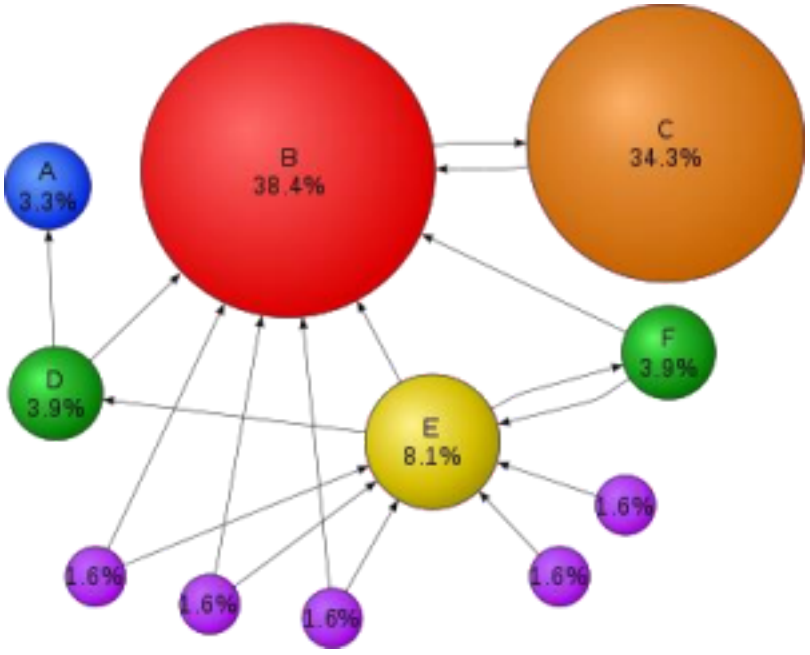
Алгоритм PageRank

PageRank — сімейство алгоритмів оцінки важливості веб-сторінок за допомогою розв'язання систем лінійних рівнянь. Для кожної сторінки обчислює дійсне число, чим більше число — тим «важливіша» сторінка.
Замість прямого підрахунку кількості посилань PageRank інтерпретує посилання сторінки А на сторінку Б як голос сторінки А на користь сторінки Б. Після цього PageRank оцінює рейтинг сторінки відповідно до

кількості отриманих голосів.

PageRank також враховує значимість кожної сторінки, що отримала голос, адже голоси деяких сторінок є важливішими, і відповідно до цього підвищується значущість сторінки, посилання на яку вони містять. Важливі сторінки отримують більш високу оцінку PageRank і відображаються на перших позиціях результатів пошуку. Для визначення значущості сторінки технологія Google використовує колективний інтелект всесвітньої мережі. Людина не бере участі в обробці результатів. Пошукова система Google не спотворює інформацію про позиції платою за результати пошуку.

За основу PageRank був обраний академічний підхід оцінки важливості публікації автора по числу її згадок в бібліографічних посиланнях інших авторів. Для адаптації до застосування в Інтернет в алгоритм були внесені наступні зміни: вага кожного посилання враховується індивідуально і нормується за кількістю посилань на сторінці. Крім того, PageRank може бути інтерпретовано в термінах випадкового блукання.



Основною метою алгоритму було поліпшення *якості* відповідей на пошукові запити. Розробники PageRank зазначили, що станом на листопад 1997 року, лише одна із найпоширеніших пошукових систем була здатна вказати власну сторінку в перших 10 результатах при запиті на власну назву (була здатна знайти сама себе).

Запропонований алгоритм, натомість, брав до уваги структуру і текст гіперпосилань. При цьому:

1. Алгоритм PageRank моделював випадкову подорож користувача інтернет починаючи з випадкової сторінки. Чим більше випадкових відвідувачів діставались сторінки, тим вище її рейтинг. Розробники припустили, що в такий спосіб вдасться уникнути проблем зі спамом за ключовими словами.
2. Вміст сторінки оцінювали не лише за ключовими словами в ній, а й в сторінках, що на неї посилаються. Розробники припустили, що зловмисникові буде важче спотворити вміст сторінок, що посилаються на його сторінку, тільки якщо він не контролює інші сторінки.

Значення PageRank для сторінки *A* обчислюється за такими правилами: нехай $T_1, \ldots, T_n$ — сторінки, що посилаються (цитують) сторінку *A*. Алгоритм також використовує коефіцієнт демпінгу *d*, значенням якого знаходяться в проміжку між 0 та 1, та зазвичай має значення 0.85. Функція *C(T)* дорівнює кількості посилань, що виходять зі сторінки *T*. Тоді значення PageRank сторінки *A*, *PR(A)*, дорівнює:

$$PR(A) = (1-d) + d\sum_{i=1}^{n}\frac{PR(T_i)}{C(T_i)}$$

При цьому, значення PageRank — це випадкові величини сума яких для всіх сторінок дорівнюватиме 1.

Кроки MapReduce

Алгоритм PageRank можна розглядати як задачу обчислення важливості веб-сторінок на основі їх взаємозв'язків. Для розрахунку важливості використовується ітераційний підхід, в якому кожна сторінка отримує рейтинг на основі рейтингів сторінок, які посилаються на неї. Алгоритм PageRank можна реалізувати за допомогою MapReduce, який дозволяє розподілити обчислення між різними вузлами кластера. Ось кроки MapReduce в алгоритмі PageRank:

1. Map: Кожна сторінка вхідного графа представляється як ключ значення, де ключ - це URL сторінки, а значення - це список URL

сторінок, на які посилається дана сторінка. У фазі Map кожна сторінка розбивається на пари ключ-значення, де ключ - це URL сторінки, а значення - це список URL сторінок, на які посилається дана сторінка.

2. Reduce: У фазі Reduce виконується обчислення рейтингу кожної сторінки. Кожна сторінка отримує початковий рейтинг, який розподіляється рівномірно між усіма сторінками. Далі виконується ітераційний процес, в якому кожна сторінка отримує рейтинг на основі рейтингів сторінок, які посилаються на неї. У фазі Reduce виконується обчислення нового рейтингу кожної сторінки на основі рейтингів сторінок, які посилаються на неї.
3. Map: У фазі Map виконується перетворення даних, щоб підготувати їх для наступної ітерації. Кожна сторінка розбивається на пари ключ значення, де ключ - це URL сторінки, а значення - це список URL сторінок, на які посилається дана сторінка, а також її новий рейтинг.
4. Reduce: У фазі Reduce виконується обчислення нового рейтингу кожної сторінки на основі рейтингів сторінок, які посилаються на неї. Цей процес повторюється доти, поки рейтинги сторінок не стабілізуються.
5. Map: У фазі Map виконується перетворення даних, щоб підготувати їх для виведення результатів. Кожна сторінка розбивається на пари ключ-значення, де ключ - це URL сторінки, а значення - це її рейтинг.
6. Reduce: У фазі Reduce виводяться результати - рейтинги сторінок. Кожна сторінка виводиться як пара ключ-значення, де ключ - це URL сторінки, а значення - це її рейтинг.

Питання

1. Як визначається важливість веб-сторінок в алгоритмі PageRank?
2. Які є основні поняття та принципи роботи алгоритму PageRank?
3. Як використовується матриця переходів у алгоритмі PageRank?
4. Як використовується вектор рейтингів у алгоритмі PageRank? 5. Як використовується ітераційний підхід у алгоритмі PageRank? 6. Як впливає структура веб-графа на реалізацію алгоритму PageRank? 7. Як впливає зміна параметрів алгоритму PageRank на результати його роботи?
8. Які є модифікації алгоритму PageRank та їх вплив на результати

роботи алгоритму?

9. Як використовується алгоритм PageRank в пошукових системах та соціальних мережах?
10. (**Додаткове питання**) Які є переваги та недоліки алгоритму PageRank порівняно з іншими алгоритмами визначення важливості веб сторінок?